BIL 463 | Assignment 1 — Part B Report

Ceren Sinmeç • 21120205040 • Luma • Python + PLY (Path B)

1. Language Design

Luma, değişkenler, aritmetik ifadeler, koşullar ve döngüler için tasarlanan küçük bir imperative language örneğidir. let, if, else, while, for, return, print, true ve false reserved keywords olarak tanımlandı. Operatörler: =, ==, !=, <, <=, >, >=, +, -, *, /, %, &&, ||, !. Parantezler, süslü parantezler, virgül ve noktalı virgül punctuation olarak kullanılır.

Multi-character operators ayrı token kurallarıyla tanımlandı. == iki ASSIGN yerine tek EQ tokenı üretir. Identifier önce bütünüyle eşleştirilir, sonra reserved dictionary kontrol edilir: if → IF; ifx → IDENTIFIER. Bu davranış maximal munch ve keyword priority ile uyumludur. Whitespace ve comments token olarak döndürülmez; block comment içindeki satır sonları sayılır.

2. Testing & Bugs

Windows ortamında Python 3.14, PLY 3.11 ve tiktoken 0.14.0 kullanılarak üç örnek dosya çalıştırıldı. Ayrıca 22 otomatik unittest kontrolü gerçekleştirildi: Ran 22 tests in 0.016s — OK. Başarısız test bulunmadı. Kapsam: keywords, identifiers, integer/float literals, operators, comments, line-number tracking, invalid-character recovery ve unterminated block comment.

Üç hata riski ve çözümü: (1) == işaretinin iki = olarak ayrılması EQ kuralı ve adjacent-operator testleriyle kontrol edildi. (2) ifx ifadesinin IF + x biçiminde bölünmesi, tam identifier eşleşmesinden sonra keyword lookup uygulanarak önlendi. (3) Kapanmamış /* yorumuna özel hata bildirimi eklendi; test_unterminated_block başarılı geçti.

Ek edge cases: .5, 2., 1e10, 2.5E-3, _name2, ifx, @, # ve çok satırlı yorumlar. Geçersiz karakterler için satır numarasıyla hata kaydedilir; lexer sonraki karakterlerden token üretmeye devam eder.

3. AI Usage + BPE Comparison

OpenAI ChatGPT, ilk lexer taslağının, test senaryolarının, dokümantasyonun ve teknik incelemenin hazırlanmasında kullanıldı. AI önerileri doğrudan doğru kabul edilmedi; kod davranışı ve gerçek terminal çıktılarıyla kontrol edildi. Teknik incelemede kullanılan üç istem, ikinci sayfada aynen verilmiştir.

Doğrulama özeti: 22/22 otomatik test başarılı; üç örnek dosyada toplam 139 lexer tokenı ve 182 BPE tokenı ölçüldü.

3. AI Usage + BPE Comparison (devam)

Teknik incelemede kullanılan istemler (verbatim):

1. Python ve PLY kullanılarak geliştirilen Luma programlama dilinin lexical analysis kurallarını teknik açıdan incele. Özellikle maximal munch, keyword priority, multi-character operators ve numeric literal tanımlarına odaklan. Regex kuralları arasında oluşabilecek öncelik çakışmalarını ve hatalı tokenization ihtimallerini belirle. Dilin mevcut sözdizimini değiştirmeden, tespit edilen sorunlar için örnek girdiler ve uygulanabilir düzeltme önerileri sun.

2. PLY tabanlı Luma lexer uygulamasının test kapsamını değerlendir. Keywords, identifiers, integer ve float literals, operators, single-line ve multi-line comments ile invalid characters için oluşturulan test senaryolarını incele. Özellikle line-number tracking, error recovery, ambiguous token boundaries ve edge cases üzerinde dur. Eksik test senaryolarını belirle, her senaryo için beklenen token çıktısını açıkla ve mevcut uygulamanın hata yönetimini iyileştirmeye yönelik teknik öneriler sun.

3. Luma programlama dilinde kullanılan rule-based lexer ile GPT-4 modelinin tiktoken kütüphanesindeki BPE tokenization yaklaşımını karşılaştır. Valid programs, edge cases ve invalid input örnekleri üzerinden token sayılarındaki farklılıkları değerlendir. Numeric literals, whitespace, multi-character operators ve unsupported characters için iki yöntemin davranışlarını açıkla. Lexer tokenization yönteminin parser açısından, BPE yönteminin ise neural language models açısından neden daha uygun olduğunu teknik gerekçelerle değerlendir. Ayrıca Türkçe karakterlerin ve kelime yapılarının BPE token sayısına etkisini incele.

AI incelemesi ve düzeltmeler

İlk taslakta kapanmamış block comment için özel hata bildirimi bulunmuyordu; ilgili kural ve regression test eklendi. Keyword prefix ve operator priority davranışları otomatik testlerle kontrol edildi. BPE sayıları tahmin edilmedi; Windows terminalindeki gerçek tiktoken çıktıları esas alındı.

BPE Comparison

Test dosyası	Lexer	BPE
test1.txt	51	58
test2.txt	61	82
test3.txt	27	42
Toplam	**139**	**182**

BPE, whitespace ve comments dahil ham metinden subword parçaları üretirken Luma lexer sözdizimsel token türlerini belirler ve yorum/boşlukları atlar. Üç dosyada BPE toplam 43 token daha fazladır. 42, lexer için INTEGER iken ölçülen BPE çıktısında tek token olmuştur. @ lexer için illegal character, BPE için normal bir metin tokenıdır. Lexer parser için; BPE neural language models için uygundur. Tırnaklarla birlikte "Derleyici belirteçleri ayrıştırır" ifadesi 16 BPE tokenına ayrıldı; Türkçenin eklemeli yapısı ve vocabulary içindeki parça sıklıkları sonucu etkileyebilir.